

Алгоритм решения

Перед применением алгоритма необходимо проверить условия сходимости метода простой итерации. В случае настоящих входных данных (см. раздел «Постановка задачи») выполняется достаточное условие сходимости (подробнее см. раздел «Результаты и их анализ»). Перед началом алгоритма исходное матричное уравнение домножается на A^T для обеспечения симметричности основной матрицы. Тогда матрица исходная матрица A станет симметричной и положительно определённой. Это гарантирует корректные собственные значения матрицы и облегчит нахождение параметра t по формуле:

$$t = \frac{2}{(\lambda_{\max}(A) + \lambda_{\min}(A))}$$

Будем строить последовательность приближений $x^{(k)}$. Выберем первое приближение $x^{(0)}$. По условию лабораторной работы необходимо взять $x^{(0)} = b$.

Остальные приближения $x^{(k)}$ будем считать по формуле:

$$x^{(k+1)} = x^{(k)} - t \cdot (Ax^{(k)} - b)$$

Или так:

$$x^{(k+1)} = Bx^{(k)} + c$$

где

$$B = E - tA, \quad c = tb$$

В покомпонентной форме:

$$x_i^{(k+1)} = x_i^{(k)} - t \sum_{j=1}^k a_{ij} x_j^{(k)} + tb_i.$$

Листинг

```
import numpy as np

def simple_iteration(A, b, x0, t, tol=1e-5, max_iter=1000):
    """
    Решение СЛАУ методом простой итерации

    Параметры:
        A (numpy.ndarray): Матрица коэффициентов.
        b (numpy.ndarray): Вектор свободных членов.
        x0 (numpy.ndarray): Начальное приближение.
        t (float): Параметр итераций.
        tol (float): Погрешность.
        max_iter (int): Максимальное число итераций

    Возвращает:
        x (numpy.ndarray): Приближённое решение.
        n_iter (int): Число выполненных итераций.
    """
    x = x0

    for n_iter in range(max_iter):
        # Вычисление нового приближения
        x_new = x - t * (A @ x - b)

        # Проверка критерия остановки
        if np.max(np.abs(x_new - x)) < tol: #np.linalg.norm(x_new - x, ord=np.inf) < tol:
            return x_new, n_iter + 1

        x = x_new

    raise ValueError("Метод не сошёлся за заданное число итераций.")

def is_positive_definite_eigenvalues(A):
    """Проверка положительной определённости матрицы через собственные значения."""
    eigenvalues = np.linalg.eigvals(A) # Вычисление собственных значений
    return np.all(eigenvalues > 0) # Проверка, что все значения положительны

def diagonal_dominant_coefficient(A):
    diag = []
    notdiag = []
```

```

for i in range(len(A)):
    diag.append(np.abs(A[i,i]))
    notdiag.append(sum([np.abs(A[i,j]) for j in range(len(A[i])) if i != j]))
    if diag[i] < notdiag[i]:
        return False

np.savetxt(fname='diag_dominant_res.txt', X=list(zip(diag, notdiag)))

return True

# Пример матрицы A и вектора b
A = np.loadtxt(fname='A.txt')
A_t = np.transpose(A)
A = A_t @ A
b = np.loadtxt(fname='B.txt')
b = A_t @ b
w,_ = np.linalg.eig(A)
t = 2 / np.abs((np.max(np.real(w)) + np.min(np.real(w)))) # Параметр
x0 = b
another_b = np.eye(A.shape[0], A.shape[1]) - t * A
diagonal_dominant_coefficient(another_b)
w, v = np.linalg.eig(another_b)
with open('spec_radius.txt', 'w') as f:
    f.write(str(np.max(np.abs(w))))

# Решение СЛАУ
x, iterations = simple_iteration(A, b, x0, t)
error = (A @ x) - b
np.savetxt(fname='x_res.txt', X=x)
np.savetxt(fname='error.txt', X=error)
with open('iterations.txt', 'w') as f:
    f.write(str(iterations))

print(f"Решение: {x}")
print(f"Число итераций: {iterations}")

```

Результаты и их анализ

На описанных данных (см. раздел «Постановка задачи») алгоритм выдаёт следующее решение

$$X = \begin{bmatrix} -5.999675346313688706 \\ 2.999840748984318406 \\ 1.999975134349126771 \\ -4.000089896983578974 \\ 4.999854774936927981 \end{bmatrix}$$

Со следующим вектором невязки R:

$$R = Ax - b$$

$$R = \begin{bmatrix} -6.571478248895701313e - 06 \\ -1.086108545322872487e - 06 \\ -5.434880778310002825e - 06 \\ 3.070558920015287185e - 06 \\ -1.258859776420706567e - 06 \end{bmatrix}$$

$$\|R\| = 1.258859776420706567e - 06$$

По результатам Лабораторной работы №3 вектор невязки метода Якоби R2 на тех же входных данных:

$$R2 = \begin{bmatrix} 7.665686396762794175e - 07 \\ 3.961590078205290411e - 08 \\ 6.927931961442368447e - 07 \\ 7.857348061079960644e - 08 \\ -2.610807456449038000e - 06 \end{bmatrix}$$

$$\|R2\| = 2.610807456449038000e - 06$$

$$P1 = \begin{bmatrix} 9.546000000000000041e - 01 \\ 1.494599999999999929e + 00 \\ 1.2007000000000000101e + 00 \\ 1.1806000000000000094e + 00 \\ 1.4067000000000000061e + 00 \end{bmatrix} \quad P2 = \begin{bmatrix} 3.7670000000000000348e - 01 \\ 3.3160000000000000059e - 01 \\ 6.28100000000000001027e - 01 \\ 5.173999999999999710e - 01 \\ 8.791999999999999815e - 01 \end{bmatrix}$$

Где P1 – вектор диагональных элементов матрицы B,

P2 – вектор сумм недиагональных элементов строк матрицы B

Нетрудно видеть, что по координатам $P1 > P2$. Значит, матрица B обладает свойством диагонального преобладания. Тогда метод сходится.

В процессе отыскания решения исходной системы линейных уравнений алгоритмом было выполнено 41 итерация по сравнению с 11 итерациями метода Якоби

В методе простой итерации $B = E - tA$, где t — параметр релаксации. Однако выбор оптимального t может быть сложным.

В методе Якоби матрица итераций $\mathbf{B} = -\mathbf{D}^{-1}(\mathbf{L} + \mathbf{U})$, где \mathbf{D} — диагональная часть \mathbf{A} , а \mathbf{L} и \mathbf{U} — нижняя и верхняя треугольные части.

Используя встроенные функции библиотеки numpy для вычисления собственных значений матрицы \mathbf{B} получим следующее.

Спектральный радиус матрицы \mathbf{B} в методе Якоби - 0.3211255411762186

Спектральный радиус матрицы \mathbf{B} в методе простой итерации - 0.713924442837992

Таким образом скорость сходимости метода Якоби можно объяснить меньшим спектральным радиусом матрицы \mathbf{B} .